



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
PATTERN RECOGNITION
GRUPO: 3CM11



IDENTIFICACIÓN DE ÁREAS
EN UNA IMAGEN



Alumnos:
Ortiz Chávez Karla
Rojas Fernández Rafael

ÍNDICE

Contenido

1. INTRODUCCIÓN	2
1.1 OBJETIVO	2
1.1.1Objetivos Particulares:	2
2. MARCO TEÓRICO	3
2.1 CONCEPTOS BASICOS	3
2.2 FASES DE UN CLASIFICADOR	4
2.2.1 Fase de aprendizaje	4
3. DISEÑO DE UN CLASIFICADOR PARAMÉTRICO BAYESIANO.	5
3.1 Preprocesamiento	6
CLASIFICADOR PARAMÉTRICO BAYESIANO DISTRIBUCIÓN GAUSSIANA	8
4. RESULTADOS	10
.....	13
5. CONCLUSIONES	13
Ortiz Chavez Karla	13
6. BIBLIOGRAFÍA	14

1. INTRODUCCIÓN

En este trabajo, una de las cosas que se pueden observar es que, el reconocimiento de patrones y los clasificadores, no son algo tan sencillo de realizar, hay toda una serie de pasos para poder llevarlo a cabo de la manera adecuada, y en un principio mi mayor pregunta era ¿Qué es el Conjunto de muestras de aprendizaje (CMA)? Y pasando los días e investigando pude ver y entender a que se referían con esto, y, dicho sea de paso, considero que el CMA es lo más importante dentro de el reconocimiento de patrones.

Para este trabajo, se considera un clasificador que nos permita identificar 3 distintas áreas dentro de una imagen, las cuales son (Cielo, Bosque, Tierra) como se muestra en la figura 1. Debemos basarnos en los tres componentes R, G, B para poder distinguir los colores de la imagen de entrada.

Después de iniciar el trabajo sola, un compañero



Figura 1. Imagen con las tres áreas (Cielo, Bosque, Tierra).

1.1 OBJETIVO

Implementar el algoritmo del clasificador paramétrico Bayesiano haciendo uso del aprendizaje supervisado para las clases con distribución normal, con el cual se permita clasificar tres tipos de texturas naturales, las cuales son la Tierra, el Cielo y el Bosque, a partir de una imagen de entrada basadas en los componentes R, G, B.

1.1.1Objetivos Particulares:

- Fase de aprendizaje
 - Análisis de los requerimientos del problema de segmentación
 - Definición de rasgos y características
 - Preprocesamiento de la imagen
 - Segmentación
 - Diseño del clasificador Bayesiano
 - Regla de aprendizaje
 - Selección de rasgos

- Obtención de la media y la matriz de covarianza de acuerdo con el clasificador
- Fase de recuperación
 - Aplicación de las funciones discriminantes para patrones desconocidos.
 - Introducir los nuevos patrones a las clases pertenecientes.
 - Implementación del clasificador.

2. MARCO TEÓRICO

2.1 CONCEPTOS BASICOS

El reconocimiento de patrones es una disciplina científica que tiene como objetivo clasificar objetos en un numero especifico de clases. Los objetos para reconocer se denotan como entradas.

Dentro del reconocimiento de patrones tenemos los siguientes conceptos importantes a tomar en cuenta:

- ✓ Reconocimiento: Es una serie de pasos.
- ✓ Rasgo: Característica específica de algo como, por ejemplo: color, ancho, alto, etc.
- ✓ Patrón: Descripción del objeto mediante sus características.
- ✓ Clase: Conjunto de patrones que describen el mismo objeto.

Teniendo claro esto ahora podemos proceder con los problemas del reconocimiento de patrones que se estudian dentro de esta unidad que son los siguientes:

- ✓ Clasificación Supervisada: Dadas ciertas clases, encontrar una regla para clasificar una nueva observación dentro de las clases existentes.
- ✓ Clasificación No supervisada: Se tiene un conjunto de datos y se deben establecer clases.

El aprendizaje supervisado se caracteriza por el conjunto de datos que se usa para entrenar el sistema, los cuales son datos etiquetados, en este aprendizaje se asume que hay un conjunto de datos de entrenamiento disponibles y el clasificador se diseña aprovechando la información a priori. Consta de dos pasos esenciales los cuales son: *el entrenamiento y la hipótesis*.

Este clasificador se basa del aprendizaje supervisado, para este trabajo se hizo uso del clasificador paramétrico bayesiano con distribución gaussiana, podemos constatar que el clasificador Bayesiano es un método clásico que se basa en el supuesto de que el problema de la decisión se enfoca en términos probabilísticos y que todas las probabilidades relevantes resultan conocidas. En este clasificador se utiliza la distancia de Mahalanobis ya que las probabilidades a priori son iguales.

Hay que tomar en cuenta que este clasificador es paramétrico dicho esto podemos definir que al ser paramétrico es que se conoce la estructura estadística de las densidades de la probabilidad conocida.

Distancia de mahalanobis:

Es una forma de determinar la similitud entre dos variables aleatorias multidimensionales. Y se define por la siguiente expresión:

$$d(i, j) = (W_i, -W_j)'V^{-1}(W_i, -W_j)$$

Función discriminante: (FD o fd)

Es una aplicación escalar sobre el vector x, de tal suerte que en el caso de utilizar el procedimiento de regionalización de espacio de patrones equivalente a un signo:

- +, si $f(x) > 0$
- -, si $f(x) = 0$ el vector se queda indeterminado en cuanto a una clasificación.

2.2 FASES DE UN CLASIFICADOR

2.2.1 Fase de aprendizaje

a) Extracción de características: Extraer información relevante para la clasificación a partir de las entidades cuantificables.

b) Selección de características: En la parte de la selección de características hacemos uso de nuestras extracciones, con lo cual podemos decir que se escogen las características que realmente serán funcionales para nuestro trabajo.

c) Aprendizaje: Ajustar el modelo inicial y realizar predicciones futuras. Se puede decir, que nuestro clasificador aprenderá respecto a las entradas dadas.

Clasificador paramétrico bayesiano

Al ser paramétrico hacemos uso de la **aproximación paramétrica** en donde se conoce la estructura estadística de las clases funcionales de densidad de probabilidad conocida.

El algoritmo que se debe seguir para la elaboración del clasificador es el siguiente:

- ❖ Se elige una muestra de patrones clasificada de antemano con n clases $\{c_1, c_2, \dots, c_n\}$ y la métrica d_M distancia de Mahalanobis.
- ❖ Con base en la muestra y para cada clase C_i estimar los parámetros: media para cada clase $\{m_i, m_j\}$ así como las matrices de covarianza de cada clase $\{C_i, C_j\}$.

$$\text{Media: } m_i = \frac{1}{p} \sum_{k=1}^p (x_{ij}) \quad \text{Matriz de Covarianza } C_k = \frac{1}{p-1} \sum_{k=1}^p (x_i - m_i)(x_i - m_i)^t$$

- ❖ Generar funciones discriminantes $d_{M(ij)}(X)$ para cada par de clases c_i, c_j de forma que:

$$d_M^2(x_k, m_i) = (x_k - m_i)C_i^{-1}(x_k - m_i)^t$$

- ❖ En el momento de clasificar (recuperación) el patrón x será clasificado en la clase c_i si cumple lo siguiente:

$$x \in C_i \text{ si } d_M^2(x_k, m_i) < d_M^2(x_k, m_j), \forall i \neq j, i, j = 1, 2, \dots, c$$

3. DISEÑO DE UN CLASIFICADOR PARAMÉTRICO BAYESIANO.


En la figura 1, podemos observar 3 regiones en donde podemos describir los colores a partir del R, G, B o de píxeles y los cuales conforman a una región donde estas regiones serán denominadas clases:

- C_1 Bosque.
- C_2 Tierra.
- C_3 Cielo.

Una de las cosas a tomar en cuenta dentro de este trabajo es que los píxeles de la imagen, $f(x, y)$ corresponderán a un patrón dentro de una clase, esto quiere decir que; $x_i \in C_i$ donde $C_i = \{C_1, C_2, C_3\}$. Al obtener dichos datos se podrá diseñar un clasificador el cual permitirá identificar cada una de las clases.

Para poder realizar este proceso, se debe realizar lo siguiente:

- Preprocesamiento de la imagen
 - Abrir imagen
 - Convertir a ng
 - Extracción del canal verde
 - Extraer los canales RGB
- Segmentación
 - Multiumbralización
 - Operación puntual OR
 - Generación del descriptor de texturas para cada clase C_i .
 - Asociación de cada píxel $f(x, y) \in C_i$.
 - Definición del CMA
- Aprendizaje
 - Vector de entrada R, G, B
 - Cálculo del centroide, vector media para cada clase C_i .
 - Algoritmo Bayesiano
 - Pruebas
- Implementación del clasificador
 - Interfaz gráfica
 - Extracción de características
 - Clasificador



3.1 Preprocesamiento

El primer paso dentro de nuestro problema es el abrir la imagen para así poder extraer los pixeles que contiene, con esto nos referimos a extraer la textura de cada región de nuestras tres clases, y con esto poder saber si estos rasgos pueden describir a los patrones de cada una de las clases. Una vez obtenidos, se llevarán a la fase de aprendizaje y por último la implementación del clasificador paramétrico bayesiano.

Características de la imagen de entrada:

- Imagen a color R, G, B donde nuestro rango de valor para cada canal es de [0, 255] niveles de color.
- Píxel R, G, B que será llamado $x_i \in C_i$
- Tamaño de la imagen: $M \times N = 334 \times 218$.

Definición del vector de entrada R, G, B.

Para poder describir cada región o clase, se hará mediante el análisis de la textura, por lo cual se necesita extraer cada píxel, y estos conforman nuestros vectores de entrada para el clasificador.

Píxel (x,y) para cada canal (R, G, B): $\rightarrow x_i = (R, G, B) \rightarrow x_i = \begin{pmatrix} R \\ G \\ B \end{pmatrix}$

Para cada clase C_i , se requiere almacenar los pixeles que conforman este tipo de textura, por ejemplo, tomaremos un píxel cualquiera para cada clase, la representación del vector de rasgos que describe a cualquier patrón para cada una de las clases tendrá la forma siguiente:

- Clase Bosque: $x_i \Rightarrow (R, G, B) \rightarrow x_i \begin{pmatrix} R \\ G \\ B \end{pmatrix} = \begin{pmatrix} 59 \\ 43 \\ 20 \end{pmatrix} \in C_1$
- Clase Tierra: $x_i \Rightarrow (R, G, B) \rightarrow x_i \begin{pmatrix} R \\ G \\ B \end{pmatrix} = \begin{pmatrix} 118 \\ 62 \\ 39 \end{pmatrix} \in C_1$
- Clase Cielo: $x_i \Rightarrow (R, G, B) \rightarrow x_i \begin{pmatrix} R \\ G \\ B \end{pmatrix} = \begin{pmatrix} 208 \\ 233 \\ 253 \end{pmatrix} \in C_1$

▪ Segmentación:

La segmentación es una parte del preprocesamiento de la imagen nos sirve para reconocer un objeto, y además es necesario tener una descripción de estos. Deben ser independientes del tamaño, localización u orientación del objeto.

- Extracción de los niveles de gris para cada uno de los canales (R, G, B), donde haremos la especificación del tamaño de cada una de nuestras clases, donde después de realizarlo se obtuvo lo siguiente:
- ✓ Clase Bosque C_1 la cual contiene 1,805 datos.
- ✓ Clase Tierra C_2 la cual contiene 8,753 datos.
- ✓ Clase Cielo C_3 la cual contiene 680 datos.

▪ Multi umbralización

Es un método que busca segmentar las imágenes creando una partición binaria de las intensidades de las imágenes. Trata de determinar un valor de intensidad llamado umbral que separa las clases deseadas.

La umbralización es uno de los métodos más importantes de la segmentación de imágenes. Se define el umbral como una función que convierte una imagen con diferentes tonalidades en una imagen en blanco y negro. Si la imagen original es $f(x, y)$, la imagen umbralizada $g(x, y)$ y se fija un umbral U ($0 < U < 255$), la operación de umbralizado se define como:

$$g(x, y) = 255 \text{ si } f(x, y) > \text{Umbral}$$

$$g(x, y) = 0 \text{ si } f(x, y) \leq \text{Umbral}$$

▪ Operación lógica “OR”




Figura 3. Imagen procesada, a) imagen original, b) imagen con la segmentación de la región boscosa, c) extracción de la región boscosa en b).

Donde se hizo uso de la imagen a) y la imagen b) de la figura... y consiste en una operación píxel a píxel entre dos imágenes tomando una como primer operador lógico y la otra como segundo operador. En este caso, la primera imagen es una imagen a color donde todos los píxeles de esta son distintos de cero se consideran verdaderos, mientras que los ceros o negros se consideran falsos. Y en caso de la imagen b, al ser una imagen binaria el color blanco se considera como verdadero y el negro como falso. Al realizar dicha operación, se obtiene la imagen c).

CLASIFICADOR PARAMÉTRICO BAYESIANO DISTRIBUCIÓN GAUSSIANA

- **Fase de aprendizaje:**

1. Se elige una muestra de patrones clasificada de antemano con n clases $\{C_1, C_2, C_3\}$ y la métrica d_M (distancia de Mahalanobis).

El Conjunto de Muestras de Aprendizaje (CMA) consta de un total de 11,238 muestras, donde en cada clase tenemos:

$$C_1 = \{X_1, \dots, X_{1805}\} \text{ con } i = 1 \text{ hasta } 1805$$

$$C_2 = \{X_1, \dots, X_{8753}\} \text{ con } j = 1 \text{ hasta } 8753$$

$$C_3 = \{X_1, \dots, X_{680}\} \text{ con } k = 1 \text{ hasta } 680$$

Teniendo en cuenta nuestras clases, se calcula el patrón representante:

$$Z_i = \frac{1}{P} \sum_{j=1}^P x_{ij}$$

Donde P es el número de elementos o patrones en la muestra que pertenece a C_i y Z_i es el vector medio, representante de la clase C_i .

- Solución:

$$Z_1 = \frac{1}{1805} \sum_{j=1}^{1805} x_{ij} = \begin{pmatrix} 102.11 \\ 79.13 \\ 55.81 \end{pmatrix}$$

$$Z_2 = \frac{1}{8753} \sum_{j=1}^{8753} x_{ij} = \begin{pmatrix} 169.84 \\ 136.83 \\ 101.58 \end{pmatrix}$$

$$Z_3 = \frac{1}{680} \sum_{j=1}^{680} x_{ij} = \begin{pmatrix} 201.59 \\ 215.4 \\ 221.64 \end{pmatrix}$$

Y una vez obtenido nuestro representante pasamos a obtener la matriz de covarianza para cada una de nuestras clases:

$$\text{Matriz de Covarianza } C_k = \frac{1}{p-1} \sum_{i=1}^p (x_i - m_i)(x_i - m_i)^t$$

$$C_1 = \begin{bmatrix} 1110.74 & 875.58 & 743.61 \\ 875.58 & 740.40 & 658.92 \\ 743.61 & 658.92 & 629.53 \end{bmatrix}$$

$$C_2 = \begin{bmatrix} 1663.05 & 1534.69 & 1325.04 \\ 1534.69 & 1471.16 & 1300.34 \\ 1325.04 & 1300.34 & 1205.75 \end{bmatrix}$$

$$C_3 = \begin{bmatrix} 1106.44 & 207.28 & 2.52 \\ 207.28 & 5860.72 & -4.76 \\ 2.52 & -4.76 & 161.91 \end{bmatrix}$$

Se generarán funciones discriminantes $d_{M(ij)}(x)$ para cada par de clases C_i y C_j de forma que:

$$d_M^2(x_k, m_i) = (x_k, m_i)C_i^{-1}(x_k, m_i)^t$$

- **Fase de recuperación:**

Cuando hacemos el clasificador el patrón x será clasificado en la clase i si cumple lo siguiente:

- Probamos el clasificador con 2 patrones distintos para los cuales realizamos las funciones discriminantes y definimos a cada clase pertenece:

➤ Patrón. (0,64,205)

Clase Bosque:

$$d_M^2(x_k, m_i) = (x_k, m_i)C_1^{-1}(x_k, m_i)^t$$

$$d_M^2(x_k, m_i) = (-102.11, -15.13, 148.19) \begin{pmatrix} 0.02179 & -0.0417 & 0.1800 \\ -0.0417 & 0.0998 & -0.0551 \\ 0.0180 & -0.0551 & 0.0380 \end{pmatrix} \begin{pmatrix} -102.11 \\ -15.13 \\ 149.19 \end{pmatrix}$$

$$d_M^2(x_k, m_i) = 668.63$$

Clase Tierra:

$$d_M^2(x_k, m_i) = (x_k, m_i)C_2^{-1}(x_k, m_i)^t$$

$$d_M^2(x_k, m_i) = (-102.11, -15.13, 148.19) \begin{pmatrix} 0.0224 & -0.0345 & 0.0125 \\ -0.0345 & 0.0675 & -0.0349 \\ 0.0125 & -0.0349 & 0.0247 \end{pmatrix} \begin{pmatrix} -102.11 \\ -15.13 \\ 149.19 \end{pmatrix}$$

$$d_M^2(x_k, m_i) = 469.16$$

Clase Cielo:

$$d_M^2(x_k, m_i) = (x_k, m_i)C_3^{-1}(x_k, m_i)^t$$

$$d_M^2(x_k, m_i) = (-102.11, -15.13, 148.19) \begin{pmatrix} 0.0009 & -3.2193 & -1.5107 \\ -3.2193 & 0.0675 & 5.5508 \\ -1.514 & 5.5535 & 0.0061 \end{pmatrix} \begin{pmatrix} -102.11 \\ -15.13 \\ 149.19 \end{pmatrix}$$

$$d_M^2(x_k, m_i) = 147.33$$

La definición para la clase C_i

$$x \in C_i \text{ si } d_M^2(x_k, m_i) < d_M^2(x_k, m_j), \forall i \neq j, i, j = 1, 2, \dots, c$$

Podemos entonces concluir respecto a los valores obtenidos en cada clase que el patrón pertenece a la clase Cielo.

$$(0,64,205) \in C_3$$

4. RESULTADOS

Vista de las clases en un gráfico 3d.

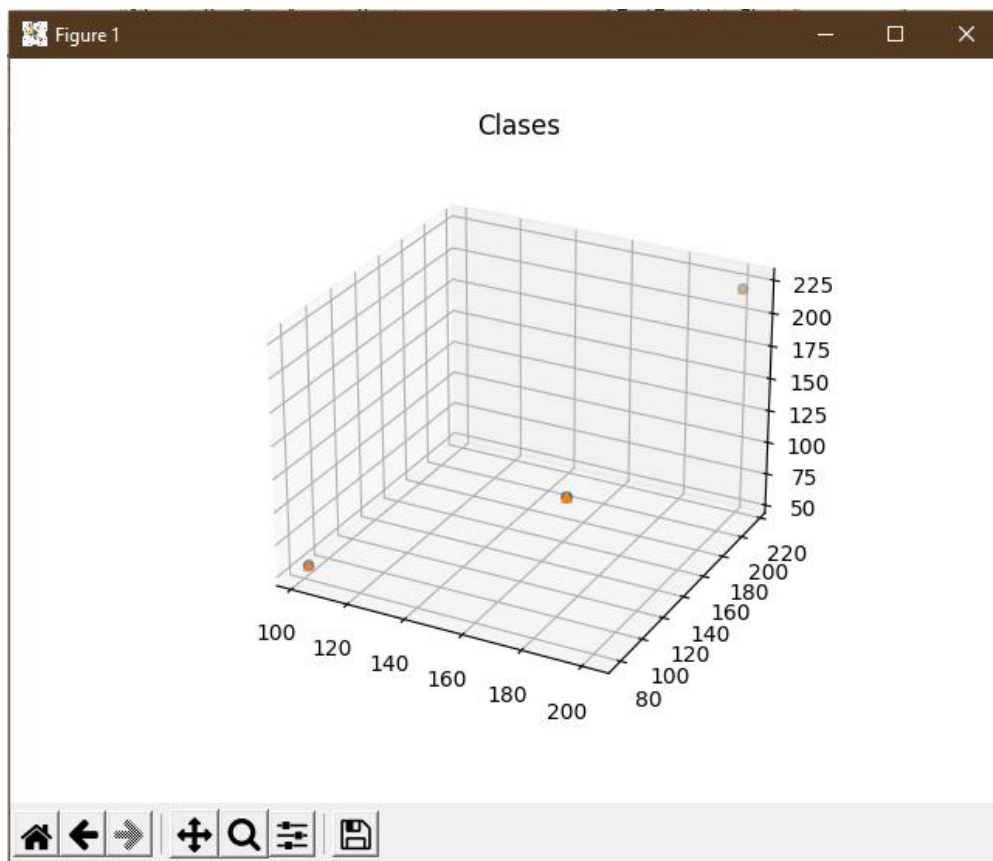


Figura 4. Representación de la Clase Bosque, Clase Tierra y Clase Cielo dentro de un plano.

Para las pruebas finales, escogimos como primera imagen a la que funcionó como nuestro conjunto de muestra de aprendizaje, y se obtuvo lo siguiente:

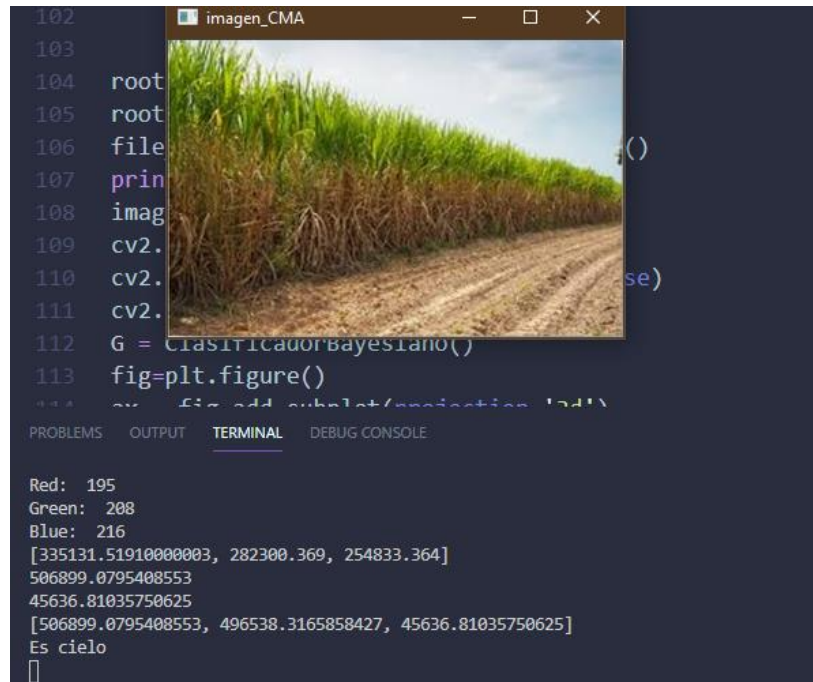


Figura 5. Clic en el área del cielo, salida correcta del clasificador: Es cielo.



Figura 6. Clic en el área Bosque con salida correcta del clasificador: Es bosque.

Nuestra segunda imagen, fue tomada de internet.

```
101 | cv2.destr
102 |
103 |
104 | root
105 | root
106 | file
107 | prin
108 | imag
109 | cv2.
110 | cv2.
111 | cv2.imshow('imagen_CMA', imagen)
112 | G = ClasificadorBayesiano()
113 | fig=plt.figure()
114 | ax = fig.add_subplot(projection='3d')
PROBLEMS OUTPUT TERMINAL DEBUG CONSOLE
Red: 47
Green: 45
Blue: 4
[-129622.8609, -107661.711, -96085.236]
193972.94311455905
193972.94311455905
[193972.94311455905, 766804.730896808, 1052920.1974405388]
Es bosque
□
```

Figura 7. Clic en el área Bosque con salida Es bosque del clasificador.

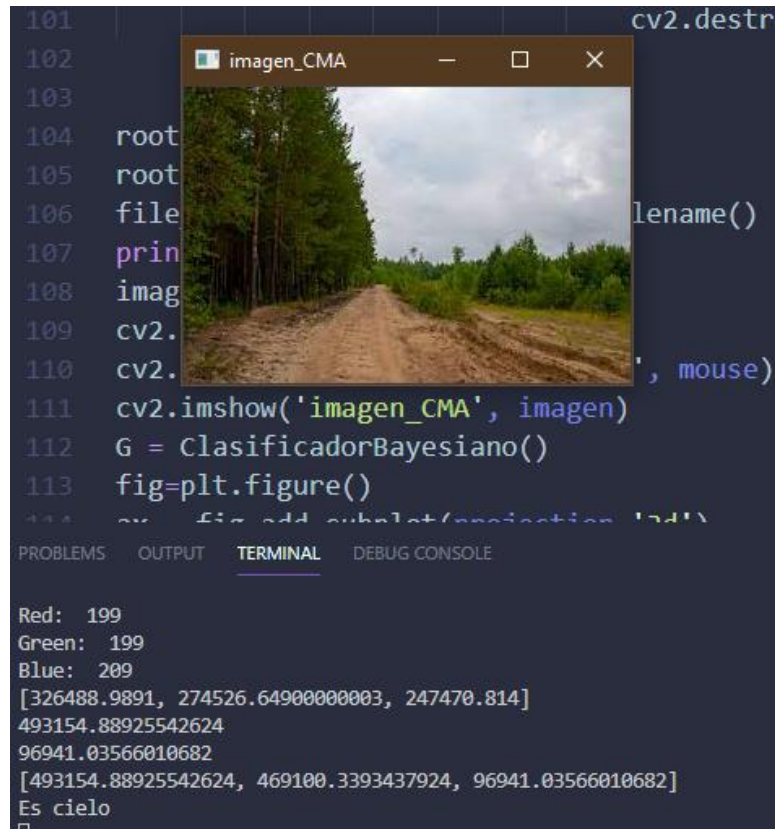


Figura 8. Clic en el área Cielo salida correcta del clasificador.

5. CONCLUSIONES

Ortiz Chavez Karla: Como lo escribí en la introducción, este trabajo en un principio resulto difícil para mí, y no porque no supiera hacerlo, más bien, no sabía lo que debía hacer, o por donde empezar, pero con el paso de los días y la ayuda de la profesora pude comprender lo necesario para poder desarrollar un clasificador. Lo importante de la materia es aprender a aplicar los clasificadores, y ver como funcionan, seguir los pasos para poder realizar la aplicación. Después de días y obteniendo el conjunto de muestras de aprendizaje, el trabajo se agilizó ya que, lo demás resultó ser mas sencillo. Considero que el tener la media y la matriz de covarianza dentro del clasificador lo hace un poco más exacto, así como considerar e introducir nuevos patrones desconocidos lo hace aun mas exacto. Fue una buena práctica, en donde pude obtener aprendizajes de distinto tipo, y que seguramente, serán utilizados y perfeccionados.

Rojas Fernández Rafael: Se pudieron cumplir los objetivos propuestos para la práctica. A lo largo que se implementó el programa se pudieron entender lo que implican los factores como los patrones desconocidos dentro del aprendizaje supervisado. El cómo influyen ciertos componentes para ayudar a tener más exactitud respecto a la clasificación de patrones seleccionados. También se pudieron observar maneras en que se pueden segmentar imágenes de modo que se diferencien los componentes en caso de dividir en clases una imagen.

6. BIBLIOGRAFÍA

Algoritmos de Segmentación . (24 de abril de 2021). Obtenido de
<http://bibing.us.es/proyectos/abreproy/11863/fichero/PFC%252FCapitulo+III.pdf>

Martinsanz, G. P. (2002). *Visió por computadora: imagenes digitales y aplicaciones*. Alfa y Omega.

Meza, M. E. (2005). Notas del curso de Reconocimiento de Patrones . ESCOM_IPN.

Pattern Recognition . (2021). En S. Theororidis. AP.